

物流公司支援線規劃之多階段最佳化方法

Multi-Stage Optimization for Supporting Lines in Logistics Companies

郭忠義、楊宏傑

國立臺北科技大學資訊工程系

Department of Computer Science and Information Engineering,

National Taipei University of Technology

Email: {jykuo, t113598012}@ntut.edu.tw

摘要

隨著電子商務快速發展與需求多樣化，物流配送規劃面臨更高的效率與成本挑戰。本研究以某物流公司配送資料為基礎，針對固定主線下因需求波動所產生之超載與支援線調度問題，提出一套兼顧實務可行性與最佳化效益之配送規劃方法。相較於車輛路徑問題(Vehicle Routing Problem, VRP)可自由調整路線，本研究納入物流實務限制，並將問題建構為分階段之組合最佳化架構，分別處理店鋪抽取、重新分配與支援線規劃，以降低搜尋空間並提升解品質。方法結合基因演算法(Genetic Algorithm, GA)與蟻群演算法(Ant Colony Optimization, ACO)，並透過修復機制確保解之可行性。此外，本研究除於物流公司實際人工編排結果進行比較外，亦與Solomon 資料集上進行驗證。結果顯示，在實務資料中，本方法可有效降低整體配送成本與支援線需求，而在Solomon 資料集中，相較基準方法於多數案例中可取得相近或更佳之結果。

關鍵字：路徑最佳化、基因演算法、蟻群演算法、車輛路徑問題

一、緒論

隨著電子商務快速發展與消費需求多樣化，物流配送規劃面臨更高的效率與成本挑戰。車輛路徑問題(Vehicle Routing Problem, VRP)[1]多假設路線可自由調整，並透過基因演算法(Genetic Algorithm, GA)[2]與蟻群演算法(Ant Colony Optimization, ACO)[3]等元啟發式方法求解。

然而，在實務情境中，物流公司已建立固定主線配送架構，各路線之店鋪服務順序不可任意變動，且配送決策具有明確的階層性。當配送需求波動導致主線超載時，需在維持既有順序下進行店鋪抽取與重新分配，並規劃支援線以完成配送任務。

為解決此問題，本研究提出一套分階段之組合最佳化架構，納入主線結構、容量限制與時間窗等限制，將主線店鋪抽取、候選店鋪分配與支援線規劃視為不同子問題，並依其特性設計對應之演算法策略，以降低搜尋空間並提升解品質，提供具效率與可行性的配送規劃方法，並作為物流配送相關問題之基礎。

二、背景知識及相關文獻探討

2.1 Vehicle Routing Problem

VRP 為典型 NP-hard 組合最佳化問題，旨在針

對同一組同質車輛，依據顧客需求量進行配送路線之分配與規劃，其核心目標是在滿足各種營運限制之條件下，最小化整體配送成本。在基本 VRP 中，須滿足以下基本限制條件：

1. 每個顧客都必須完成配送。
2. 每輛車必須從配送中心出發並返回配送中。
3. 每個顧客僅允許被拜訪一次且僅能由一輛車負責配送。

近期相關研究中，多聚焦於 VRP 的延伸問題，其中以時間窗車輛路徑問題(Vehicle Routing Problem with Time Windows, VRPTW)[4]與兼具自有與委外之車輛路徑問題(Vehicle Routing Problem with Private Fleet and Common Carrier, VRPPC)[5]最具代表性。VRPTW 在基本限制外額外加入時間窗限制，要求每個顧客必須於指定時間區間內接受服務，車輛必須在最早開始時間後才能進行服務，且不得晚於最晚結束時間，確保在規定時間內完成顧客節點的服務。而 VRPPC 在 VRP 中既有的自有車輛(Private Fleet)限制外，引入了外部物流業者(Common Carriers)作為支援。當自有車輛(Private Fleet)無法滿足所有需求，或是服務特定顧客的成本過高時，可選擇將部分訂單外包給外部物流業者，以最小化總物流成本。

2.2 Genetic Algorithm

基因演算法靈感來自達爾文進化論中適者生存及基因傳遞的概念，並已被廣泛應用於各類最佳化問題。於 GA 中，每個候選解稱為個體(Individual)，由染色體(Chromosome)表示，染色體由多個基因(Gene)組成。透過對個體進行選擇(Selection)、交配(Crossover)與變異(Mutation)，使較高適應值的個體在演化過程中更容易被保留，逐步產生更優質的解。

在相關研究方面，Beasley 等人[6]提出了一種結合問題特定知識的遺傳演算法框架。透過雙階段貪婪修復運算子(DROP/ADD Repair Operator)提升解之可行性與品質。Maroof 等人提出 HGA-SIH(Hybrid Genetic Algorithm-Solomon Insertion Heuristic)[7] 混合式基因演算法，透過結合 SIH(Solomon Insertion Heuristic)，以提升初始解的品質與多樣性，並應用於 VRPTW。

此外，針對高維度且具子問題相依性之問題，合作式共同演化基因演算法(Cooperative Co-evolutionary Genetic Algorithm, CCGA)[9]採用分而治之(Divide-and-Conquer)概念，將原始問題分解為多個子問題，並由不同子族群(subpopulations)分別

進行演化搜尋，再透過合作機制組合各子族群之代表個體形成完整解，以提升大型問題之搜尋效率與整體解品質。

2.3 Ant Colony Optimization

蟻群演算法為 Dorigo 所提出的元啟發式演算法，透過模擬螞蟻在覓食過程中釋放費洛蒙尋找最短路徑的行為來解決組合最佳化問題。每隻螞蟻以輪盤選擇法選擇下一個節點，選擇機率根據當前路徑的費洛蒙濃度與啟發式信息決定，此決策機制屬於序列式決策(sequential decision)，使其特別適合應用於路徑規劃問題。

在延伸架構方面，針對 VRPTW，Gambardella 提出 MACS-VRPTW(Multiple Ant Colony System for Vehicle Routing Problems with Time Windows)[10]，採用雙蟻群協作架構，分別最佳化車輛數量與總行駛距離，透過費洛蒙資訊交換實現多目標協同搜尋。Bell 等人[11]則進一步將多蟻群架構應用於 VRP，透過為各配送車輛設置獨立費洛蒙，降低多車路線規劃時的相互干擾，並結合 2-opt 局部搜尋、區域更新及候選名單機制，以提升大規模問題之解品質與求解效率。

在相關應用方面，Molina 等人針對異質車輛途程問題並考慮時間窗限制(Heterogeneous Vehicle Routing Problem with Time Windows, HVRPTW)，提出結 ACS 與 Memetic Algorithm 之混合式方法，並結合變動鄰域禁忌搜尋(Variable Neighborhood Tabu Search, VNTS)進行區域搜尋，以提升解品質。同時引入 Holding List 機制以管理未服務顧客。實驗結果顯示，該方法於多組基準測試中可有效降低總配送成本並提升收斂表現。

2.4 方法限制與比較探討

VRP 及其延伸模型多假設配送路線可於規劃階段進行全域重排，雖能獲得數學上之最佳解，但往往忽略實務中的營運限制，導致結果難以落地執行。在本研究之實際物流場域中，物流公司已建立固定主線配送架構，店鋪服務順序具穩定性，且調度決策亦呈現明確的階層性，即優先消化主線運能，僅在無法滿足需求時才啟用支援線。

然而，現有 VRP 研究較少考量此類限制，且人工規劃方式高度仰賴經驗，面對多路線同時超載時，難以進行全局最佳化評估，亦耗費大量時間成本。因此，本研究聚焦於在既有主線架構下進行有限度調整，並提出兼顧實務可行性與計算效率的最佳化方法，以縮短決策時間並提升整體配送效益。

三、研究方法

本章將介紹所採用方法架構及處理流程，3.1 節介紹問題案例描述，3.2 節介紹方法架構及架構圖。

3.1 問題案例描述

本研究使用由物流公司提供的初始路線資料，

該資料為物流公司依據以往配送經驗所規劃的主線配送路線，即車輛行駛路線與配送順序的初步規劃。本研究旨在解決在已有主線配送、材積量以及時間窗限制的條件下，重新規劃支援線的配送問題。由於每日各店鋪的實際配送需求可能變動，因此當主線配送車輛無法滿足所有需求，便需要調整配送策略，以避免延誤且提升整體效率。

為符合實務配送情境，在配送過程中，本研究根據「A 物流公司」路線規劃資料，設置限制條件以確保配送過程順利進行。條件如下：

1. 配送車貨物裝載率上限為 100%。
2. 店鋪配送需要符合時間窗限制，到店時間應於表定前一小時至後三十分鐘內。
3. 車輛配送路線總配送時長不能超過五小時。
4. 主線可以支援運送支援候選店鋪，但原店鋪配送順序不能調整。
5. 支援路線規劃，先依照地理位置分群，由最遠的店鋪先進行配送。
6. 店鋪分為近、中和遠區，近區與中區店鋪無需考慮方向問題，遠區店鋪若第一間店鋪已挑選物流中心以北的店鋪，後續不得挑選物流中心以南的店鋪，東西向亦然。

在此問題架構下，本研究針對物流公司之配送路徑規劃問題進行探討，建構一個以實務營運為導向之最佳化模型。具體而言，本研究採用階層式目標(Hierarchical Objective)，依照優先順序分為兩層，首先最小化支援線所需之車輛數量，其次在滿足主要目標之條件下，進一步最小化整體配送之總行駛距離。此種階層式決策機制可同時兼顧車輛數量控制與配送成本，提升整體配送效益。其中式(1)表示支援車輛數量，式(2)表示總行駛距離。

$$f_{vehicle}(S) = \sum_{h \in H} \sum_{\substack{j \in N \\ (j \neq 0)}} x_{0,j}^h \quad (1)$$

$$f_{travel}(S) = \sum_{k \in K} \sum_{i \in N} \sum_{\substack{j \in N \\ (j \neq i)}} d_{i,j} \cdot x_{i,j}^k \quad (2)$$

3.2 系統架構

本研究提出的方法其架構如圖 1 所示，針對物流公司之配送路徑規劃問題，建構四個模組，包含資料模組(Data Module)、路線模組(Route Module)、API 模組(API Module)與評估模組(Evaluation Module)。

首先，讀取原始配送路線資料(Original Route Data)，透過資料模組轉換為後續路線模組可以處理的資料格式，使其符合路線模組所需之輸入格式，同時 Open Source Routing Machine(OSRM)建立配送店鋪之間的距離矩陣，提供路線規劃所需之行駛距離資訊。在路線模組中，透過店鋪抽取(Store Extraction)將超出承載限制之主線店鋪進行篩選，並形成候選店鋪集合，後續再根據候選店鋪分配

(Store Allocation) 和支援線規劃 (Support Line Planning) 將候選店鋪重新分配至主線或支援線並結合 Google Maps Platform 提供的 Routes API 估算實際行車時間。完成路線規劃後，路線評估 (Routes Evaluation) 對規劃結果進行分析與比較，最終輸出最佳化路線結果 (Optimized Route Data)，提供作為實務規劃的參考。




圖 1 系統架構圖

3.2.1 資料前處理

本階段針對原始取得相關資料進行彙整、轉換與清理，以建立後續自動化路線編排流程所需之結構化資料集。相關資料包含路網資料、各店滯店時間、店鋪主檔及既有人工編排配送路線資料。

在資料前處理過程中，首先將資料來源進行格式統一與欄位對應，並依據路線編號與店鋪編號進行資料整合，以建立每條路線對應之配送路線資料與店鋪清單。同時，針對缺失值、不合理數值及重複紀錄進行檢查與修正，以確保資料的一致性與正確性。此外，亦將時間欄位轉換為統一格式，並整理各店鋪之地理座標、配送時間窗、店鋪所需材積量與滯店時間等資訊，作為後續路線規劃與演算法計算之依據。

3.2.2 超載路線店鋪抽取

本階段針對原始主線路線中發生超載之情形進行店鋪抽取，以確保各路線之總需求量符合車輛容量限制。首先對各路線之總材積進行檢查，當其超出車輛承載上限時，則需移除部分店鋪，使剩餘路線恢復為可行解。為進行超載路線之調整，本研究採用 CCGA 進行求解，其編碼對應為單一子族群所構成之二元向量表示，如式(3)所示。

$$Z_{k,n}^g = [z_{k,n,1}^g, z_{k,n,2}^g, \dots, z_{k,n,|M_k|}^g] \quad (3)$$

在選擇機制上，採用輪盤式選擇 (Roulette Wheel Selection)，其選擇機率定義如式(4)所示。

$$p_{k,n}^g = \frac{F_{k,n}^g}{\sum_{r=1}^{N_{sub}} F_{k,r}^g} \quad (4)$$

交配採用均勻交配 (Uniform Crossover)，突變則採用隨機突變 (Bit Flip Mutation)，以維持多樣性並避免早熟收斂。由於 CCGA 中各子族群僅負責部分決策變數，其個體無法獨立構成完整解，須結

合其他子族群之代表解 (context solution) 形成完整候選解後進行評估，式(5)表示透過支援線數量與總行駛距離之加權組合評估解之品質。

$$F(S) = C \cdot f_{vehicle}(S) + f_{travel}(S) \quad (5)$$

由於交配與突變可能破壞原有解之結構，導致部分主路線違反車輛容量限制，因此本研究於演化過程中導入修復機制，以維持解之可行性。當路線超出容量限制時，透過基於成本效率之啟發式成本函數計算各店鋪之抽取權重，並依據權重決定優先移出之店鋪。式(6)為店鋪抽取權重函數。

$$w_i = \frac{C}{n} + \theta_i \cdot d_{0,i} \quad (6)$$

3.2.3 候選店鋪分配

本階段針對超載路線店鋪抽取後所產生之候選店鋪集合重新分配至既有主線，最大化主線利用率並確保整體配送結構之可行性。為進行候選店鋪之重新分配，本研究採用 HACO 進行求解，並結合變動鄰域下降法 (Variable Neighborhood Descent, VND) 進行最佳化。

在 HACO 架構中，每次迭代由 m 隻螞蟻依據機率轉移規則逐步建構可行路徑，其轉移機率如式(7)所示。式(8)為啟發式資訊，用於反映插入路徑距離及載重成本。式(9)表示插入路徑距離之成本。而式(10)則用來評估車輛剩餘載容量與店鋪需求量的關係。

$$p_{i,j,u,k}^a = \frac{\tau_{i,u}^\alpha \cdot \eta_{i,j,u,k}^\beta}{\sum_{z \in N_i^a} \tau_{i,z}^\alpha \cdot \eta_{i,j,z,k}^\beta} \quad (7)$$

$$\eta_{i,j,u,k} = \frac{1}{\alpha_1 \cdot C_{i,j,u}^0 + \alpha_2 + C_{i,j,u}^1} \quad (8)$$

$$C_{i,j,u}^0 = d_{i,u} + d_{u,j} - d_{i,j} \quad (9)$$

$$C_{i,j,u}^1 = Q_k - L_k - v_u \quad (10)$$

於每次建構解時，系統依據式(11)進行區域費洛蒙更新，以降低已選擇路徑之費洛蒙濃度，提升搜尋過程之探索能力。每次迭代結束後，系統根據當前最佳解進行全域費洛蒙更新，強化優良路徑之搜尋方向。其中，全域費洛蒙更新機制如式(12)所示，而費洛蒙增量則依據最佳解品質定義如式(13)所示。

$$\tau_{i,j} = (1 - \rho) \cdot \tau_{i,j} + \rho \cdot \tau_0 \quad (11)$$

$$\tau_{i,j} = (1 - \rho) \cdot \tau_{i,j} + \rho \cdot \Delta \tau_{i,j} \quad (12)$$

$$\Delta\tau_{i,j} = \begin{cases} \frac{1}{F(S)} & \text{if the edge } (i,j) \in S, \\ 0 & \text{otherwise,} \end{cases} \quad (13)$$

此外，為進一步強化解品質，本研究於每隻螞蟻完成路徑建構後導入 VND 局部搜尋機制，透過多種鄰域結構進行改善，並依序探索不同鄰域集合，當當前鄰域無法產生更佳解時即切換至下一鄰域，直至解無法再被改善為止。其過程可表示為式(14)。

$$S^* = \arg \min_{S' \in N_k(S)} F(S') \quad (14)$$

3.2.4 支援線規劃

本階段針對無法成功分配到既有主線的候選店鋪進行支援線規劃。此階段的核心問題為 VRPTW，因此系統採用 MACS 並結合 VND 進行最佳化，在 MACS 架構中，不同蟻群分別針對不同目標進行搜尋，以在降低車輛數量的同時降低總行駛距離。其中，ACS-VEI 負責優先降低車輛使用數量求，ACS-DIST 則在既定車輛配置下進一步最佳化路徑結構，以降低總行駛距離。

在 MACS 架構中，每次迭代由 m 隻螞蟻依據機率轉移規則逐步建構可行路徑，其轉移機率如式(15)所示。式(16)為距離啟發資訊，表示當前店鋪到各候選店鋪之移動成本，用於反映路徑距離及成本。式(17)則表示當前店鋪至候選店鋪之移動成本。

$$p_{i,j}^m = \frac{\tau_{i,j} \cdot \eta_{i,j}^\beta}{\sum_{z \in N_i^m} \tau_{i,z} \cdot \eta_{i,z}^\beta} \quad (15)$$

$$\eta_{i,j} = \frac{1}{\Phi_{i,j}} \quad (16)$$

$$\Phi_{i,j} = \max(1.0, d_{i,j} - IN_j) \quad (17)$$

此外，為反映實務限制，本研究依據店鋪與物流中心的地理位置，將路線劃分為近區、中區與遠區，同時結合東、西、南、北方向的區域劃分，以減少跨區配送帶來的效率問題，以提升整體配送效率。此外，所編排之支援線均需遵守五小時以內的行駛時間限制，同時取得各店鋪的預定到達時間，確保每間店鋪的服務時間落在其允許的時間窗範圍內。

MACS 之費洛蒙更新機制與 VND 局部搜尋流程同 3.2.3 節所述，其中區域費洛蒙更新、全域費洛蒙更新與費洛蒙增量分別如式(11)、式(12)與式(13)所示，而 VND 局部搜尋則如式(14)所示。

3.2.5 路線整合與評估

本階段針對前述演算法所產生之配送路線進行可行性驗證與效能評估。利用 Google Maps Platform 所提供之 Routes API 取得各條路線於實際道路網路環境下之行駛距離與預估行駛時間，以反

映真實交通條件，進而驗證主線與支援線之路線之實務可行性。於完成路線可行性驗證後，進一步將主線與支援線加以整合，形成最終配送路線，作為後續配送與分析評估之基礎。

為系統性評估配送規劃結果之整體效能，本研究將相關結果轉化為多項量化指標進行分析，包括所需車輛數量、總行駛距離、平均車輛裝載率以及時間窗滿足比例等，以評估配送規劃結果之整體效能與路線合理性。彙整輸出最終配送路線資料及其對應之指標，作為後續比較不同規劃策略、分析，以及實際配送系統應用與決策支援之參考依據。

四、實驗結果

本章將介紹實驗流程與結果，4.1 節介紹本實驗描述實驗中使用與比較之超參數，4.2 節比較系統與人工編排之結果差異，並將實驗方法與其他文獻進行比較。

4.1 實驗流程

本研究將評估該流程在物流公司提供之資料集上的路線編排效果，並進一步檢視整體路線編排績效指標，以確認結果是否符合預期，從而驗證其在實務配送環境中的可行性與穩定性。此外，為更全面評估所提方法之效能，亦將進一步與基準方法進行比較分析。

在超參數設定方面，本研究依各階段所使用的演算法針對不同問題，其設定如表 1 所示。

表 1 超參數設定

問題類型	超參數	設定值
Store Extraction	迭代次數	200
	族群大小	20
	交配機率	0.8
	突變機率	0.1
Store Allocation	迭代次數	200
	螞蟻數量	50
	費洛蒙函數	1
	啟發函數	1
	蒸發速率	0.7
Support Line Planning	搜尋時間	100
	螞蟻數量	50
	啟發函數	7
	蒸發速率	0.5

4.2 實驗結果與比較

本研究於完成自動化路線編排流程後，針對物流公司所提供之資料集進行評估，並以每日配送需求為單位，共 26 組案例進行實驗分析。系統完成路線規劃後，進一步從車輛數量、總行駛距離、平均路線裝載率、平均準點率及規劃時間等指標進行量化評估，以檢視整體路線編排效能。此實驗旨在驗證所提方法於實際配送情境下之可行性與有效性，相關結果彙整如表 2、

表 3 所示。其中 NV 表示車輛數量，TD 表示總行駛距離，U 表示裝載率，O 表示準點率。

表 2 本研究與物流公司人工編排平均比較表

指標	本研究	人工編排	Gap(%)
NV	91.79	100.88	-9.01
TD	3981.46	4211.42	-5.46
U	0.91	0.83	9.64
O	0.98	0.94	4.26

表 3 各方法平均花費時間

指標	本研究	人工編排
平均規劃時間(小時)	0.25	1.5

結果顯示，本研究方法能有效降低配送規劃時間，並於車輛數量、總行駛距離、車輛使用率及裝載率等指標上，皆較人工編排具有較佳表現，能在縮短規劃時間之基礎上，同時提升整體配送效率與車輛資源利用率。

本研究進一步與相關文獻中具代表性之方法作為基準進行比較，並於 Solomon VRPTW Benchmark[12]測試資料上進行實驗，並於相同評估指標下分析各方法之表現差異。所採用之測試資料之節點數量皆為 100 個，並依據客戶分布特性可分為 C-R 與 RC 三類，其中 C 類為群聚型(Clustered)，客戶節點呈現明顯群聚分布，R 類為隨機型(Random)，客戶位置均勻隨機分布，RC 類則為混合型(Random-Clustered)，同時包含隨機與群聚特性，以評估不同空間分布條件下之方法表現。本研究方法與基準(Baseline)方法比較如表 4 所示，其中 NV 表示車輛數量，TD 表示總行駛距離。

表 4 實例類別比較結果

實例類別	方法	NV	TD
R1	Baseline	12.83	1209.01
	本研究	12.79	1234.93
R2	Baseline	4.72	1087.59
	本研究	3.15	995.42
C1	Baseline	10	838.75
	本研究	10	828.38
C2	Baseline	3	590.35
	本研究	3.01	592.58
RC1	Baseline	12.26	1391.48
	本研究	12.44	1381.75
RC2	Baseline	5	1134.43
	本研究	3.46	1167.7

從表 4 中結果可知，本研究方法與基準方法於各實例類別之整體表現大致相當。由於 VRPTW 採用階層式目標，其優先順序為先最小化車輛數量，再最小化總行駛距離，因此車輛數量之表現為主要評估指標。實驗結果顯示，本研究方法相較於 Baseline 可降低約 6.23%之車輛數量，並同時降低 1.0%之總行駛距離，顯示本研究方法在符合

VRPTW 階層式最佳化目標下，能有效降低車輛使用數量，同時維持良好之路線品質。

表 5 實例比較結果

比較結果	實例數量
優於基準方法	28
相當基準方法	12
劣於基準方法	16

表 5 為本研究與基準方法各實例整體比較結果，本研究方法相較於 baseline 於 56 組案例中，有 28 組案例取得較佳結果，同時約 12 組的案例與 Baseline 相同，其餘案例則呈現相近但未明顯優於基準方法之結果。顯示本方法在多數情境下具有相近或更佳解。進一步觀察可發現，本研究方法在多數測試案例中能有效維持或改善車輛使用數，在多數測試情境中具優勢，顯示其在實務上良好的應用效果。

五、結論

本研究針對物流配送中固定主線架構下之路線最佳化問題進行探討，考量實務上主線店舖順序不可變動、需求波動導致超載，以及需啟用支援線之情境，將問題建構為具時間窗限制之多階段組合最佳化問題。

為提升求解效率與解品質，本研究將問題拆分為主線超載店舖抽取、候選店舖重新分配及支援線規劃三個子問題，並依其特性分別設計基因演算法與蟻群演算法進行求解，同時結合修復機制以確保解之可行性。實驗結果顯示，本研究方法於物流公司實務資料中能有效降低支援線需求並改善整體配送效率，在 Solomon VRPTW 測試資料集中亦展現穩定性，特別在降低車輛數量方面具有優勢，顯示本方法兼具實務應用性與求解能力。

然而，本研究仍以靜態配送情境為主要假設，未來可進一步延伸至動態需求或即時調度問題，例如考慮即時訂單插入、交通變動或多物流中心協同配送等情境。此外，亦可結合深度學習或強化學習方法，以提升大規模問題下之決策能力與效果，進一步擴展本研究於智慧物流領域之應用價值。

參考文獻

- [1] P. Toth and D. Vigo, *The vehicle routing problem*. SIAM, 2002.
- [2] S. Mirjalili, "Genetic algorithm," in *Evolutionary algorithms and neural networks: theory and applications*: Springer, 2018, pp. 43–55.
- [3] M. Dorigo, M. Birattari, and T. Stutzle, "Ant colony optimization," *IEEE computational intelligence magazine*, vol. 1, no. 4, pp. 28–39, 2007.
- [4] K. C. Tan, L. H. Lee, Q. Zhu, and K. Ou, "Heuristic methods for vehicle routing problem with time windows," *Artificial*

- intelligence in Engineering*, vol. 15, no. 3, pp. 281–295, 2001.
- [5] J. Euchi, "The vehicle routing problem with private fleet and multiple common carriers: Solution with hybrid metaheuristic algorithm," *Vehicular Communications*, vol. 9, pp. 97–108, 2017.
 - [6] P. C. Chu and J. E. Beasley, "A genetic algorithm for the multidimensional knapsack problem," *Journal of heuristics*, vol. 4, no. 1, pp. 63–86, 1998.
 - [7] A. Maroof, B. Ayvaz, and K. Naeem, "Logistics optimization using hybrid genetic algorithm (hga): A solution to the vehicle routing problem with time windows (vrptw)," *IEEE Access*, vol. 12, pp. 36974–36989, 2024.
 - [8] M. Mutingi and C. Mbohwa, "Grouping genetic algorithms," 2017.
 - [9] X. Ma *et al.*, "A survey on cooperative co-evolutionary algorithms," *IEEE Transactions on Evolutionary Computation*, vol. 23, no. 3, pp. 421–441, 2018.
 - [10] L. M. Gambardella, É. Taillard, and G. Agazzi, "MACS-VRPTW: A multiple ant colony system for vehicle routing problems with time windows," ed: Istituto Dalle Molle Di Studi Sull Intelligenza Artificiale, 1999.
 - [11] J. E. Bell and P. R. McMullen, "Ant colony optimization techniques for the vehicle routing problem," *Advanced engineering informatics*, vol. 18, no. 1, pp. 41–48, 2004.
 - [12] *Solomon's Benchmark Problems*. [Online]. Available:
<https://www.sintef.no/projectweb/top/>